## Data cleaning template for R modeling

- added the new 200 data points from Prolific 2
- to compare how the new data's mobility values are different from the previous
- final update: 15th May, included engine information

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
from matplotlib.ticker import StrMethodFormatter

In [107... # Loading the csv file for the collected responses as of "date" - data 1

df = pd.read_csv('data\CO2-Rechner_February+27,+2024_20.14.csv', header = 0)

pd.set_option('display.max_columns', None)
df.head(9)
```

**EndDate** 

**StartDate** 

Out[107]:

0	Start Date	End Date	Res
1	{"ImportId": "startDate", "timeZone": "Europe/Ber	{"ImportId": "endDate", "timeZone": "Europe/Berlin"}	{"ImportI
2	2024-01-26 17:17:08	2024-01-26 17:19:54	
3	2024-01-26 17:16:34	2024-01-26 17:26:53	
4	2024-01-26 17:18:24	2024-01-26 17:29:37	
5	2024-01-26 17:17:52	2024-01-26 17:29:44	
6	2024-01-26 17:30:04	2024-01-26 17:34:26	
7	2024-01-26 17:16:39	2024-01-26 17:36:41	
8	2024-01-26 17:35:17	2024-01-26 17:41:32	

In [108...

#old df\_selected = df.iloc[1:, [25, 50, 51, 56, 61, 83, 86, 87, 88, 89, 90, 91, 92, 93

## adding engines: 26, 27, 29, 30, 32, 33, 35, 36, 38, 39

df\_selected = df.iloc[2:, [25, 50, 51, 56, 87, 90, 91, 92, 93, 94, 95, 96, 97, 99, 106]

df\_selected.head(10)

Out[108]:	C	21.1	Q5.2	Q6.1	Q4.4	Q1.7	Q3_1.1	Q3_2.1	Q3_3.1	Q3_4.1		
	2	1	Männlich	36	2500	SPD	NaN	NaN	NaN	NaN	Beruf	
		'	iviaiiiiicii	30	2300	310	Ivaiv	Ivaiv	Ivaiv	Ivaiv	A	
	3	1	Männlich	60	1000	Bündnis 90/Die Grünen	NaN	NaN	NaN	Allgemeine oder fachgebundene Hochschulreife/A		
	4	2	Männlich	57	6500	7	NaN	NaN	NaN	NaN	Beruf A	
	5	2	Männlich	36	6500	Bündnis 90/Die Grünen	NaN	NaN	NaN	NaN		
	6	1	NaN	NaN	NaN	NaN	NaN	NaN	NaN	NaN		
	7	2	Männlich	31	2500	AfD	NaN	NaN	NaN	Allgemeine oder fachgebundene Hochschulreife/A		
	<b>8</b> 0 Weiblich			63	1500	7	NaN	NaN	Realschulabschluss (Mittlere Reife) oder gleic	NaN		
	9	1	Männlich	45	1500	CDU/CSU	NaN	NaN	Realschulabschluss (Mittlere Reife) oder gleic	NaN	Beruf A	
	10	1	Weiblich	41	1900	7	NaN	NaN	Realschulabschluss (Mittlere Reife) oder gleic	NaN		
	11	2	Weiblich	70	5400	Bündnis 90/Die Grünen	NaN	NaN	NaN	NaN		
4											•	
In [109	df_se	elec	ted.colum	nns.va	lues							
Out[109]:	array(['Q1.1', 'Q5.2', 'Q6.1', 'Q4.4', 'Q1.7', 'Q3_1.1', 'Q3_2.1', 'Q3_3.1', 'Q3_4.1', 'Q3_5.1', 'Q3_6.1', 'Q3_7.1', 'Q3_8.1', 'Q5.4', 'C02_Wohnen', 'C02_Strom', 'C02_Wohnen_Strom', 'C02_Kreuzfahrt', 'C02_Flugreisen', 'C02_ÖPNV', 'C02_Auto1', 'C02_Auto2', 'C02_Auto3', 'C02_Auto4', 'C02_Auto5', 'C02_Auto_Gesamt', 'C02_Mobilität', 'C02_Ernährung', 'C02_Sonstiger_Konsum', 'Öffentliche_emissionen', 'C02_Gesamt', 'Einschätzung_Wohnen_Strom', 'Einschätzung_Mobilität', 'Einschätzung_Ernährung', 'Einschätzung_Sonstiger_Konsum', 'Einschätzung_Gesamt', 'Q3.1', 'Q4.1', 'Q7.1', 'Q8', 'Q11', 'Q12', 'Q15', 'Q16', 'Q19', 'Q20'], dtype=object)											

```
In [110...
          # Rename the columns
          df_selected = df_selected.rename(columns={'Q1.1': 'no_cars', 'Q5.2': 'gender', 'Q6.1':
                  'Q1.7': 'political_party',
                  'Q3_1.1': 'education1', 'Q3_2.1': 'education2', 'Q3_3.1': 'education3',
                  'Q3_4.1': 'education4', 'Q3_5.1': 'education5', 'Q3_6.1': 'education6', 'Q3_7.1
                  'Q5.4': 'postal_code', 'CO2_Wohnen': 'CO2_housing', 'CO2_Strom' : 'CO2_electric
                  'CO2_ Kreuzfahrt': 'CO2_cruise', 'CO2_Flugreisen': 'CO2_flight', 'CO2_ÖPNV': '(
                  'CO2 Auto2' : 'CO2_car2',
                  'CO2_Auto3' : 'CO2_car3', 'CO2_Auto4': 'CO2_car4', 'CO2_Auto5': 'CO2_car5', 'CC
                  'CO2_Mobilität': 'CO2_mobility', 'CO2_Ernährung': 'CO2_food', 'CO2_Sonstiger_Kc
                  'Öffentliche_emissionen': 'public_emission', 'CO2_Gesamt': 'CO2_total',
                  'Einschätzung_Wohnen_Strom': 'belief_housing_electricity', 'Einschätzung_Mobili
                  'Einschätzung_Ernährung': 'belief_food', 'Einschätzung_Sonstiger_Konsum': 'beli
                   'Q3.1': 'engine_1', 'Q4.1': 'engine_2', 'Q7.1': 'engine_3', 'Q8': 'engine_4',
                  'Q15': 'engine_7', 'Q16': 'engine_8', 'Q19': 'engine_9', 'Q20': 'engine_10'})
In [111...
          ## Creating the first batch of the collected responses
          data 1 = df selected.copy()
In [112...
          len(data_1)
          438
Out[112]:
          ## adding the batch info
In [113...
          df_selected['batch'] = 1
```

#### 2nd dataset collected

```
In [114... #### Load the dataset

df_prolific = pd.read_csv('data\Carbon+Beliefs+-+Prolific_March+10,+2024_14.10.csv', head(10)
```

**EndDate** 

**StartDate** 

Out[114]:

In [115...

	3141.1341.0		
0	Start Date	End Date	Res
1	{"ImportId":"startDate","timeZone":"Europe/Ber	{"ImportId":"endDate","timeZone":"Europe/Berlin"}	{"ImportI
2	2024-03-06 14:30:30	2024-03-06 14:36:37	
3	2024-03-06 14:30:49	2024-03-06 14:39:54	
4	2024-03-06 14:29:34	2024-03-06 14:40:05	
5	2024-03-06 14:33:30	2024-03-06 14:41:42	
6	2024-03-06 14:30:41	2024-03-06 14:41:50	
7	2024-03-06 14:30:26	2024-03-06 14:42:28	
8	2024-03-06 14:31:59	2024-03-06 14:44:35	
9	2024-03-06 14:31:33	2024-03-06 14:45:31	
			•
#	Select the columns with the variables	of interests	
##	adding engines: 27, 29, 31, 33, 35, 3	37, 39, 41, 43, 45	
df		56, 57, 62, 94, 97, 98, 99, 100, 101, 128, 134, 140, 146, 152, 153, 154, 156	
df	_prolific.head(10)		

Out[115]:	c	21.2	Q4.3	Q5.2	Q4.4	Q1.8	Q3_1.1	Q3_2.1	Q3_3.1	Q3_4.1		
	2	2	Männlich	39	4000	Einer anderen Partei	NaN	NaN	NaN	E NaN		
	3	0	Männlich	38	5000	SPD	NaN	NaN	NaN	NaN		
	4	0	Männlich	45	2500	Bündnis 90/Die Grünen	NaN	NaN	NaN	NaN		
	5	2	Männlich	22	4900	Bündnis Sarah Wagenknecht	NaN	NaN	NaN	Allgemeine oder fachgebundene Hochschulreife/A		
	6	2	Männlich	33	5000	Einer anderen Partei	NaN	NaN	NaN	NaN		
	7	0	Männlich	29	2100	Bündnis 90/Die Grünen	NaN	NaN	NaN	Allgemeine oder fachgebundene Hochschulreife/A		
	8	1	Männlich	28	3000	Bündnis 90/Die Grünen	NaN	NaN	NaN	NaN		
	9	0	Männlich	37	5000	AfD	NaN	NaN	Realschulabschluss (Mittlere Reife) oder gleic	NaN		
	10	1	Männlich	43	1900	Einer anderen Partei	NaN	NaN	NaN	NaN		
	11	1	Männlich	33	6000	FDP	NaN	NaN	NaN	NaN		
4										•		
In [116	df_pi	roli	fic.colum	nns								
Out[116]:	Triday/[101 21 104 21 105 21 104 41 101 81 102 1 11 102 2 11 102 2 11											
In [117	# rei	name	the colu	umns								

```
df_prolific = df_prolific.rename(columns={'Q1.2':'no_cars', 'Q4.3':'gender', 'Q5.2':'a
                                                                                                                           'Q3_1.1':'education1', 'Q3_2.1':'education2'
                                         'Q3_4.1':'education4', 'Q3_5.1':'education5', 'Q3_6.1':'education6', 'Q3_7.1':'
                                         'Q5.4':'postal_code', 'CO2_Wohnen':'CO2_housing',
                                         'CO2_Strom':'CO2_electricity', 'CO2_Wohnen_Strom':'CO2_housing_electricity', 'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom':'Co2_wohnen_Strom
                                         'CO2_ÖPNV':'CO2_public_transport', 'CO2_Auto1':'CO2_car1', 'CO2_Auto2':'CO2_car
                                         'CO2_Auto5':'CO2_car5', 'CO2_Auto_Gesamt':'CO2_car_total', 'CO2_Mobilität':'CO2
                                         'CO2_Sonstiger_Konsum':'CO2_other_consumption', 'Öffentliche_emissionen':'publi
                                         'Einschätzung_Wohnen_Strom':'belief_housing_electricity', 'Einschätzung_Mobilit
                                         'Einschätzung_Ernährung':'belief_food', 'Einschätzung_Sonstiger_Konsum':'belief
                                         'Einschätzung Gesamt': 'belief total',
                                           'Q3.1': 'engine_1', 'Q4.1': 'engine_2', 'Q8': 'engine_3', 'Q10': 'engine_4',
                                         'Q18': 'engine_7', 'Q20': 'engine_8', 'Q23': 'engine_9', 'Q25': 'engine_10'})
In [118...
                        ## Creating the second batch of the collected responses
                        data 2 = df prolific.copy()
                        len(data_2)
                        200
Out[118]:
In [119...
                        # adding the batch info
                        df_prolific['batch'] = 2
In [120...
                        # Concatenating the two dataframes
                        df_concat = pd.concat([df_selected, df_prolific], ignore_index=True)
                        df_concat.head()
Out[120]:
                              no cars
                                                   gender
                                                                    age income political party education1 education2 education3
                                                                                                                                                                                                                   educat
                        0
                                          1 Männlich
                                                                       36
                                                                                    2500
                                                                                                                   SPD
                                                                                                                                           NaN
                                                                                                                                                                   NaN
                                                                                                                                                                                           NaN
                                                                                                                                                                                                           Allgemeine
                                                                                                             Bündnis
                        1
                                          1 Männlich
                                                                       60
                                                                                    1000
                                                                                                                                           NaN
                                                                                                                                                                   NaN
                                                                                                                                                                                           NaN
                                                                                                                                                                                                             fachgebun
                                                                                                 90/Die Grünen
                                                                                                                                                                                                        Hochschulreif
                        2
                                                                       57
                                                                                                                        7
                                          2 Männlich
                                                                                    6500
                                                                                                                                           NaN
                                                                                                                                                                                           NaN
                                                                                                                                                                   NaN
                                                                                                             Bündnis
                        3
                                          2 Männlich
                                                                       36
                                                                                    6500
                                                                                                                                           NaN
                                                                                                                                                                   NaN
                                                                                                                                                                                            NaN
                                                                                                 90/Die Grünen
                        4
                                          1
                                                        NaN NaN
                                                                                     NaN
                                                                                                                   NaN
                                                                                                                                           NaN
                                                                                                                                                                   NaN
                                                                                                                                                                                           NaN
In [121...
                        len(df_concat)
Out[121]:
```

Note 1: cleaning the education columns: 'education\_clean'

```
# function to clean the education columns: one highest degree remains
In [122...
          def clean_education(row):
               if (pd.notna(row['education8'])) and (pd.isna(row['education7'])) and (pd.isna(row
                  (pd.isna(row['education5'])) and (pd.isna(row['education4'])) and (pd.isna(row[
                  (pd.isna(row['education2'])) and (pd.isna(row['education1'])):
                       return 'Anderer Abschluss'
              elif (pd.notna(row['education7'])):
                       return 'Doktorgrad oder Habilitation'
              elif (pd.isna(row['education7'])) and (pd.notna(row['education6'])):
                       return '(Fach-) Hochschulabschluss (Bachelor, Master, Magister, Diplom, St
               elif (pd.isna(row['education7'])) and (pd.isna(row['education6'])) and\
                    (pd.notna(row['education4'])):
                       return 'Allgemeine oder fachgebundene Hochschulreife/Abitur (Gymnasium bzw
              elif (pd.isna(row['education7'])) and (pd.isna(row['education6'])) and\
                 (pd.isna(row['education4'])) and (pd.notna(row['education5'])):
                       return 'Berufsausbildung, Lehre oder Ausbildung an einer Fachschule'
              elif (pd.isna(row['education7'])) and (pd.isna(row['education6'])) and\
                 (pd.isna(row['education4'])) and (pd.isna(row['education5'])) and (pd.notna(row[
                       return 'Realschulabschluss (Mittlere Reife) oder gleichwertiger Abschluss'
               elif (pd.isna(row['education7'])) and (pd.isna(row['education6'])) and\
                   (pd.isna(row['education5'])) and (pd.isna(row['education4'])) and (pd.isna(row
                   (pd.notna(row['education2'])):
                       return 'Hauptschulabschluss (Volksschulabschluss) oder gleichwertiger Absc
               elif (pd.isna(row['education7'])) and (pd.isna(row['education6'])) and\
                 (pd.isna(row['education5'])) and (pd.isna(row['education4'])) and (pd.isna(row['
                   (pd.isna(row['education2'])) and (pd.notna(row['education1'])):
                       return '(Noch) kein Abschluss'
              else: None
In [123...
          df_concat['education_clean'] = df_concat.apply(clean_education, axis=1)
In [124...
          df_concat = df_concat.drop(columns=['education1','education2', 'education3', 'education')
          len(df_concat)
In [125...
Out[125]:
In [126...
          df_concat.head(10)
```

Out[126]:		no_cars	gender	age	income	political_party	postal_code	CO2_housing	CO2_electrici
	0	1	Männlich	36	2500	SPD	39106	1487.5	3!
	1	1	Männlich	60	1000	Bündnis 90/Die Grünen	30966	1400.4	
	2	2	Männlich	57	6500	7	41812	1944	
	3	2	Männlich	36	6500	Bündnis 90/Die Grünen	17034	607.95	3.4
	4	1	NaN	NaN	NaN	NaN	NaN	64.3076	26.
	5	2	Männlich	31	2500	AfD	78054	1539.17575	32.666666666666666666
	6	0	Weiblich	63	1500	7	42369	2026.5	47
	7	1	Männlich	45	1500	CDU/CSU	01904	3024.864	4.
	8	1	Weiblich	41	1900	7	28237	1875.96	61
	9	2	Weiblich	70	5400	Bündnis 90/Die Grünen	12209	2722.0275	42
4									•

#### 3rd dataset collected

In [127...

#### Load the dataset

df\_prolific2 = pd.read\_csv('data\Carbon+Beliefs+-+Prolific+V2\_March+22,+2024\_11.46.csv
df\_prolific2.head(10)

**EndDate** 

**StartDate** 

Out[127]:

In [128...

0	Start Date	End Date	Res
1	{"ImportId":"startDate","timeZone":"Europe/Ber	{"ImportId": "endDate", "timeZone": "Europe/Berlin"}	{"Import
2	2024-03-21 15:17:17	2024-03-21 15:30:17	
3	2024-03-21 15:20:20	2024-03-21 15:34:03	
4	2024-03-21 15:23:39	2024-03-21 15:34:55	
5	2024-03-21 15:18:51	2024-03-21 15:36:04	
6	2024-03-21 15:25:55	2024-03-21 15:37:17	
7	2024-03-21 15:21:09	2024-03-21 15:37:29	
8	2024-03-21 15:21:09	2024-03-21 15:39:08	
9	2024-03-21 15:21:54	2024-03-21 15:39:26	
			•
#	adding engines: 27, 29, 31, 33, 35, 37	7, 39, 41, 43, 45	
df		5, 56, 57, 62, 95, 98, 100, 109, 110, 13 116, 117, 123, 129, 135, 141, 147, 148 29, 31, 33, 35, 37, 39, 41, 43, 45]]	
df	_prolific2.head(3)		

```
Out[128]:
             Q1.2
                      Q4.3 Q5.2 Q4.4
                                              Q1.9
                                                                    Q5.3 CO2_Wohnen CO2_Strom CO
                                                               Q3.6
                                                             (Fach-)
                1 Männlich
                              40 8000
                                          CDU/CSU Hochschulabschluss 80803
                                                                                  1737
                                                                                              780
                                                   (Bachelor, Master, ...
                                           Bündnis
                                                      Allgemeine oder
                                                                                              663
           3
                   Weiblich
                              22 1200
                                             Sarah
                                                       fachgebundene 06406
                                                                               2251.152
                                       Wagenknecht
                                                    Hochschulreife/A...
                                           Bündnis
                                                             (Fach-)
                0 Männlich
                              23
                                  530
                                            90/Die Hochschulabschluss 76131
                                                                                340.452
                                                                                              663
                                            Grünen (Bachelor, Master, ...
           df_prolific2.columns
In [129...
           Index(['Q1.2', 'Q4.3', 'Q5.2', 'Q4.4', 'Q1.9', 'Q3.6', 'Q5.3', 'C02_Wohnen',
Out[129]:
                  'CO2_Strom', 'CO2_Wohnen_Strom', 'CO2_ Kreuzfahrt', 'CO2_Flugreisen',
                  'CO2_ÖPNV', 'CO2_Auto1', 'CO2_Auto2', 'CO2_Auto3', 'CO2_Auto4',
                  'CO2_Auto5', 'CO2_Auto_Gesamt', 'CO2_Mobilität', 'CO2_Ernährung',
                  'CO2_Sonstiger_Konsum', 'Öffentliche_emissionen', 'CO2_Gesamt',
                  'Einschätzung_Wohnen_Strom', 'Einschätzung_Mobilität',
                  'Einschätzung_Ernährung', 'Einschätzung_Sonstiger_Konsum',
                  'Einschätzung_Gesamt_2', 'Q3.1', 'Q5.1', 'Q8', 'Q10', 'Q13', 'Q15',
                  'Q18', 'Q20', 'Q23', 'Q25'],
                 dtype='object')
           # recalculating the Einschätzung values to no. of people with CO2 footprint "higher th
In [130...
           # 100 people including the respondent
           belief_columns = ['Einschätzung_Wohnen_Strom', 'Einschätzung_Mobilität','Einschätzung_
                  'Einschätzung_Gesamt_2']
           for col in belief_columns:
               df_prolific2[col] = df_prolific2[col].astype('float')
               df_prolific2[col] = 100 - df_prolific2[col]
           df_prolific2 = df_prolific2.rename(columns={'Q1.2':'no_cars', 'Q4.3':'gender', 'Q5.2':
In [131...
                                                        'Q3.6': 'education_clean', 'Q5.3': 'postal_
                  'CO2_Strom': 'CO2_electricity', 'CO2_Wohnen_Strom': 'CO2_housing_electricity',
                                                        'CO2_Flugreisen': 'CO2_flight', 'CO2_ÖPNV':
                                                        'CO2_Auto2': 'CO2_car2', 'CO2_Auto3':'CO2_c
                  'CO2_Auto5':'CO2_car5', 'CO2_Auto_Gesamt':'CO2_car_total', 'CO2_Mobilität':'CO2
                  'CO2_Sonstiger_Konsum':'CO2_other_consumption', 'Öffentliche_emissionen':'publi
                  'Einschätzung_Wohnen_Strom':'belief_housing_electricity', 'Einschätzung_Mobilit
                  'Einschätzung_Ernährung':'belief_food', 'Einschätzung_Sonstiger_Konsum':'belief
                  'Einschätzung_Gesamt_2':'belief_total',
                   'Q3.1': 'engine_1', 'Q5.1': 'engine_2', 'Q8': 'engine_3', 'Q10': 'engine_4',
                  'Q18': 'engine_7', 'Q20': 'engine_8', 'Q23': 'engine_9', 'Q25': 'engine_10'})
           ## Creating the third batch of the collected responses
In [132...
           data_3 = df_prolific2.copy()
           len(data 3)
           201
Out[132]:
```

```
# adding the batch info
In [133...
                                                       df_prolific2['batch'] = 3
                                                       # unioning the 3rd dataset
In [134...
                                                       df_concat = pd.concat([df_concat, df_prolific2], ignore_index=True)
                                                       len(df_concat)
                                                       839
Out[134]:
In [135...
                                                       df_concat.head()
Out[135]:
                                                                                                                                                                             income political_party postal_code CO2_housing CO2_electricity CO2_electri
                                                                     no_cars
                                                                                                                  gender
                                                       0
                                                                                               1 Männlich
                                                                                                                                                               36
                                                                                                                                                                                             2500
                                                                                                                                                                                                                                                                   SPD
                                                                                                                                                                                                                                                                                                                    39106
                                                                                                                                                                                                                                                                                                                                                                                1487.5
                                                                                                                                                                                                                                                                                                                                                                                                                                                                390
                                                                                                                                                                                                                                                    Bündnis
                                                       1
                                                                                               1 Männlich
                                                                                                                                                               60
                                                                                                                                                                                             1000
                                                                                                                                                                                                                                                                                                                    30966
                                                                                                                                                                                                                                                                                                                                                                                1400.4
                                                                                                                                                                                                                                                                                                                                                                                                                                                                     39
                                                                                                                                                                                                                          90/Die Grünen
                                                       2
                                                                                                                                                                                                                                                                              7
                                                                                               2 Männlich
                                                                                                                                                                57
                                                                                                                                                                                             6500
                                                                                                                                                                                                                                                                                                                   41812
                                                                                                                                                                                                                                                                                                                                                                                       1944
                                                                                                                                                                                                                                                                                                                                                                                                                                                                     42
                                                                                                                                                                                                                                                    Bündnis
                                                       3
                                                                                               2 Männlich
                                                                                                                                                               36
                                                                                                                                                                                                                                                                                                                    17034
                                                                                                                                                                                                                                                                                                                                                                                607.95
                                                                                                                                                                                                                                                                                                                                                                                                                                                               3.85
                                                                                                                                                                                             6500
                                                                                                                                                                                                                          90/Die Grünen
                                                                                                                              NaN NaN
                                                                                                                                                                                              NaN
                                                                                                                                                                                                                                                                 NaN
                                                                                                                                                                                                                                                                                                                           NaN
                                                                                                                                                                                                                                                                                                                                                                            64.3076
                                                                                                                                                                                                                                                                                                                                                                                                                                                          26.32
```

#### Note 2: mapping urban/rural classifications with the PLZ column

```
In [136... ### loading the cleaned urban/rural classification table - EUROSTAT

df_urban_class = pd.read_csv('classification_urban_by_postal_code.csv', encoding='cp12
    df_urban_class.head()
```

Out[136]:	Unnam	ed: 0	NUTS3_	ı dı	NUTS1_NAM	IE NUTS2_NA	ME NUTS3_N	NAME POSTAI	_CODE CLA	SSIFICATIO
	0	0	DEA	1D	Nordrheir Westfale	Diisseld	lort	-Kreis Neuss	41363	PI
	1	1	DEA	1E	Nordrheir Westfale	l luccolo	lorf V	iersen	41366	Pl
	2	2	DEA	1E	Nordrheir Westfale	Diiccelo	lorf V	iersen	41748	Pl
	Westfa		Nordrheir Westfale	l )usseld	lorf V	iersen	41749	PI		
			Nordrheir Westfale	l luccolo	lorf V	iersen	41751	Pl		
4										<b></b>
In [137	# change	the	e dataty	vpe d	and join t	he classific	cation table	2		
		_= k	od.merge			df_urban_cla f_urban_clas			•	ght_on = [
Out[137]:	no_cars	5	gender	age	income p	oolitical_party	postal_code	CO2_housing	CO2_electric	ity CO2_h
	<b>0</b> 1	l M	lännlich	36	2500	SPD	39106	1487.5	3	390
	1 1	I M	lännlich	60	1000	Bündnis 90/Die Grünen	30966	1400.4		39
	2 2	2 M	lännlich	57	6500	7	41812	1944		42
	3 2	2 M	lännlich	36	6500 g	Bündnis 90/Die Grünen	17034	607.95	3	.85
	4 1	I	NaN	NaN	NaN	NaN	NaN	64.3076	26	.32
4										•
In [138	df_final	<pre>= df_final.rename(columns={'education_clean' :</pre>					'education	', 'CLASSIF	CATION':	
In [139	## Loadi	ng t	the new	clas	ssificatio	n - RLK and	KTU			
	df_urban df_urban					('new_classi	fication_u	rban_by_post	al_code.cs\	'', encodi

Out[139]:	Unname	ed: 0 POSTA	L_CODE	NUTS3_I	D NUTS1_NA	AME NUTS2_	NAME NUTS3	_NAME	RLK2022	ΚΤι	
	0	0	41363	DEA1	D Nordrh Westf	1 )110	Rhe seldorf	in-Kreis Neuss	sehr zentral	Städt	
	1	1	41366	DEA1	E Nordrh Westf	1 )110	seldorf	Viersen	sehr zentral	Städt	
	2	2	41748	DEA1	E Nordrh Westf	1)110	seldorf	Viersen	sehr zentral	Städt	
	3	3	41749	DEA1	E Nordrh Westf	1)110	seldorf	Viersen	sehr zentral	Städt	
	<b>4</b> 4		41751	DEA1	E Nordrh Westf	1 )110	seldorf	Viersen	sehr zentral	Städt	
4										•	
In [140	len(df_ur	ban_class	_new)								
Out[140]:	8319										
In [141	<pre>df_urban_class_new['POSTAL_CODE'] = df_urban_class_new['POSTAL_CODE'].astype('str')</pre>										
In [142	df_final2 df_final2		ge(df_	final, d	f_urban_cla	ss_new, lef	t_on = ['pos	tal_code	e'], rig	ht_or	
Out[142]:	no_cars	gender	age i	income p	olitical_party	postal_code	CO2_housing	CO2_ele	ctricity (	CO2_h(	
	<b>0</b> 1	Männlich	36	2500	SPD	39106	1487.5		390		
	<b>1</b> 1	Männlich	60	1000 g	Bündnis 90/Die Grünen	30966	1400.4		39		
	<b>2</b> 2	Männlich	57	6500	7	41812	1944		42		
	<b>3</b> 2 Mär		36	6500 g	Bündnis 90/Die Grünen	17034	607.95		3.85		
	<b>4</b> 1	NaN	NaN	NaN	NaN	NaN	64.3076		26.32		
4									•		
In [143	df_final2	.columns									

```
Index(['no_cars', 'gender', 'age', 'income', 'political_party', 'postal_code',
Out[143]:
                  'CO2_housing', 'CO2_electricity', 'CO2_housing_electricity',
                  'CO2_cruise', 'CO2_flight', 'CO2_public_transport', 'CO2_car1',
                  'CO2_car2', 'CO2_car3', 'CO2_car4', 'CO2_car5', 'CO2_car_total',
                  'CO2_mobility', 'CO2_food', 'CO2_other_consumption', 'public_emission',
                  'CO2_total', 'belief_housing_electricity', 'belief_mobility',
                  'belief_food', 'belief_other_consumption', 'belief_total', 'engine_1',
                  'engine_2', 'engine_3', 'engine_4', 'engine_5', 'engine_6', 'engine_7',
                  'engine_8', 'engine_9', 'engine_10', 'batch', 'Q5.1', 'education',
                  'Unnamed: 0_x', 'NUTS3_ID_x', 'NUTS1_NAME_x', 'NUTS2_NAME_x',
                  'NUTS3_NAME_x', 'POSTAL_CODE_x', 'EUROSTAT', 'Unnamed: 0_y',
                  'POSTAL_CODE_y', 'NUTS3_ID_y', 'NUTS1_NAME_y', 'NUTS2_NAME_y', 'NUTS3_NAME_y', 'RLK2022', 'KTU2022'],
                 dtype='object')
          df_final2 = df_final2[['no_cars', 'gender', 'age', 'income', 'political_party', 'educa'
In [144...
                                 'EUROSTAT', 'RLK2022', 'KTU2022', 'NUTS1_NAME_x', 'NUTS2_NAME_x',
                                 'CO2_housing', 'CO2_electricity', 'CO2_housing_electricity', 'CO2
                  'CO2_car3', 'CO2_car4', 'CO2_car5', 'CO2_car_total', 'CO2_mobility',
                   'CO2_food', 'CO2_other_consumption', 'public_emission', 'CO2_total', 'belief_hc
                                 'belief_mobility', 'belief_food', 'belief_other_consumption', 'bel
                                  'engine_1',
                  'engine_2', 'engine_3', 'engine_4', 'engine_5', 'engine_6', 'engine_7',
                   'engine_8', 'engine_9', 'engine_10']]
           df final2 = df final2.rename(columns={'NUTS1 NAME x':'NUTS1 NAME', 'NUTS2 NAME x':'NUT
In [145...
In [146...
          df final2.head(10)
```

Out[146]:		no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK2
	0	1	Männlich	36	2500	SPD	(Fach-) Hochschulabschluss (Bachelor, Master,	39106	IN	zer
	1	1	Männlich	60	1000	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	30966	PU	s zer
	2	2	Männlich	57	6500	7	Berufsausbildung, Lehre oder Ausbildung an ein	41812	PU	s zer
	3	2	Männlich	36	6500	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	17034	NaN	s perip
	4	1	NaN	NaN	NaN	NaN	None	NaN	NaN	١
	5	2	Männlich	31	2500	AfD	Allgemeine oder fachgebundene Hochschulreife/A	78054	IN	zer
	6	0	Weiblich	63	1500	7	Realschulabschluss (Mittlere Reife) oder gleic	42369	PU	s zer
	7	1	Männlich	45	1500	CDU/CSU	Berufsausbildung, Lehre oder Ausbildung an ein	01904	NaN	١
	8	1	Weiblich	41	1900	7	Realschulabschluss (Mittlere Reife) oder gleic	28237	PU	s zer
	9	2	Weiblich	70	5400	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	12209	PU	s zer
4										•

### Note 3: remove the unfinished surveys with null values

```
In [147... len(df_final2)
Out[147]: 839

In [148... ## counting the number of missing values of the urban_rural_class len(df_final2[df_final2['EUROSTAT'].isna()])
Out[148]: 201

In [149... len(df_final2[df_final2['RLK2022'].isna()])
Out[149]: 179
```

```
In [150...
           len(df_final2[df_final2['KTU2022'].isna()])
Out[150]:
In [151...
           df_count = df_final2.dropna(subset = ['CO2_housing_electricity', 'CO2_mobility', 'CO2_
                                                 'CO2_total', 'belief_housing_electricity', 'belief
                  'belief_other_consumption', 'belief_total'], how = 'any')
           len(df_count)
           709
Out[151]:
In [152...
           df_final2.columns
          Index(['no_cars', 'gender', 'age', 'income', 'political_party', 'education',
Out[152]:
                  'postal_code', 'EUROSTAT', 'RLK2022', 'KTU2022', 'NUTS1_NAME',
                  'NUTS2_NAME', 'NUTS3_NAME', 'CO2_housing', 'CO2_electricity',
                  'CO2_housing_electricity', 'CO2_cruise', 'CO2_flight',
                  'CO2_public_transport', 'CO2_car1', 'CO2_car2', 'CO2_car3', 'CO2_car4',
                  'CO2_car5', 'CO2_car_total', 'CO2_mobility', 'CO2_food',
                  'CO2_other_consumption', 'public_emission', 'CO2_total',
                  'belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total', 'batch', 'engine_1',
                  'engine_2', 'engine_3', 'engine_4', 'engine_5', 'engine_6', 'engine_7',
                  'engine_8', 'engine_9', 'engine_10'],
                 dtype='object')
          ### dropping the values for
In [153...
           df final3 = df final2.dropna(subset = ['age', 'income', 'political party', 'education'
                  'EUROSTAT', 'RLK2022', 'KTU2022', 'CO2_housing', 'CO2_electricity', 'CO2_housing_e
                  'CO2_food', 'CO2_other_consumption', 'public_emission', 'CO2_total',
                  'belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total'], how = 'any')
          len(df_final3)
In [154...
          619
Out[154]:
```

### Note 4: calclating the gap between the "belief" and "actual"

```
'belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total']
           indices = []
           for col in columns_to_check:
               indices.append(df_final3[df_final3[col].str.contains('Invalid Expression', na=Fals
           row_to_remove = list(set(flatten_extend(indices)))
           row_to_remove
          [616, 560, 576]
Out[156]:
           df_final4 = df_final3.drop(row_to_remove)
In [157...
           # Removing rows with invalid values for belief variable
In [158...
           columns_to_check = ['belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total']
           indices = []
           for col in columns_to_check:
               df_final4[col] = df_final4[col].astype('float')
               indices.append(df_final4[(df_final4[col]<0) | (df_final4[col].astype('float')>100)
           row_to_remove2 = list(set(flatten_extend(indices)))
           row_to_remove2
          [600]
Out[158]:
           df_final4 = df_final4.drop(row_to_remove2)
In [159...
          # Removing rows with invalid values for CO2 footprint
In [160...
           columns_to_check = ['CO2_housing','CO2_electricity','CO2_food']
           indices = []
           for col in columns_to_check:
               df_final4[col] = df_final4[col].astype('float')
               indices.append(df_final4[df_final4[col]==0].index.tolist())
           row_to_remove3 = list(set(flatten_extend(indices)))
           row_to_remove3
          [230]
Out[160]:
           df_final4 = df_final4.drop(row_to_remove3)
In [161...
           df_final4.columns
In [162...
```

```
Index(['no_cars', 'gender', 'age', 'income', 'political_party', 'education',
Out[162]:
                  'postal_code', 'EUROSTAT', 'RLK2022', 'KTU2022', 'NUTS1_NAME',
                  'NUTS2_NAME', 'NUTS3_NAME', 'CO2_housing', 'CO2_electricity',
                  'CO2_housing_electricity', 'CO2_cruise', 'CO2_flight',
                  'CO2_public_transport', 'CO2_car1', 'CO2_car2', 'CO2_car3', 'CO2_car4',
                  'CO2_car5', 'CO2_car_total', 'CO2_mobility', 'CO2_food',
                  'CO2_other_consumption', 'public_emission', 'CO2_total',
                  'belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total', 'batch', 'engine_1',
                  'engine_2', 'engine_3', 'engine_4', 'engine_5', 'engine_6', 'engine_7',
                  'engine_8', 'engine_9', 'engine_10'],
                 dtype='object')
          # change the datatype to number
In [163...
          # only the following columns should be datatype object: gender, 'political_party', educ
          columns_to_change = ['no_cars', 'age', 'income',
                  'CO2_housing', 'CO2_electricity', 'CO2_housing_electricity',
                  'CO2_cruise', 'CO2_flight', 'CO2_public_transport', 'CO2_car1', 'CO2_car2',
                  'CO2_car3', 'CO2_car4', 'CO2_car5', 'CO2_car_total', 'CO2_mobility',
                  'CO2_food', 'CO2_other_consumption', 'public_emission', 'CO2_total',
                  'belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total']
          for col in columns_to_change:
              if col == 'age':
                   df_final4[col] = df_final4[col].astype('Int64')
              else:
                   df_final4[col] = df_final4[col].astype('float')
          # calculate the rank in the target areas
In [164...
          # tied groups: tied groups are given the lowest number as a rank
          target_areas = ['CO2_housing_electricity', 'CO2_mobility', 'CO2_food', 'CO2_other_cons']
          target_areas2 = ['belief_housing_electricity', 'belief_mobility', 'belief_food','belief
          # finding the rank in the total numbber of respondents
          for col in target_areas:
              new_col = 'actual_rank_' + col + '1'
               df_final4[new_col] = df_final4[col].rank(ascending=False, method='min')
          # calculating how many people have higher CF and scaling it for 101 people (101 people
          # calculaing the rank in a group of 101 and subtract 1 to calculate the no. of people
          for col in target_areas:
               old_col = 'actual_rank_' + col + '1' # rank in the total group
              new_col = 'actual_rank_' + col + '2' # it is called rank but actually how many pec
              \#old: df_{final4[new_col]} = round(((df_{final4[old_col]-1)/len(df_{final4)}) * 101, 0)
              # scaling the rank to the range 1 - 101, subtract 1 to find the no.of people with
              df_final4[new_col] = round(100*(df_final4[old_col] - df_final4[old_col].min())/ (c
          # difference between the belief and the actual number of people who have higher number
          for index, col in enumerate(target areas):
               actual_col = 'actual_rank_' + col + '2'
               estimated_col = target_areas2[index]
               new_col = 'final_' + estimated_col
```

scaling formula used:

$$x_{normalized} = (b-a)rac{x-min(x)}{max(x)-min(x)} + a$$

df\_final4.tail(5) In [165... **EUROSTAT** Out[165]: no\_cars gender age income political\_party education postal\_code Allgemeine oder 834 1.00 Weiblich 22 5000.00 SPD fachgebundene 34233 IN zε Hochschulreife/A... Allgemeine oder Bündnis 835 1.00 Weiblich 26 7000.00 fachgebundene 55252 PU 90/Die Grünen ze Hochschulreife/A... (Fach-) 836 0.00 Weiblich 30 1500.00 Die Linke Hochschulabschluss 67454 ΙN zε (Bachelor, Master, ... Allgemeine oder SPD IN 837 3.00 Weiblich 20 6000.00 fachgebundene 35075 ze Hochschulreife/A... (Fach-) 838 1.00 Weiblich 29 6000.00 Hochschulabschluss 82152 IN zε (Bachelor, Master, ...

In [166... # checking the range of the calculated values for rank and differences
df\_final4.describe()

Out[166]:		no_cars	age	income	CO2_housing	CO2_electricity	CO2_housing_electricity	CO2_cruise
	count	614.00	614.00	614.00	614.00	614.00	614.00	614.00
	mean	0.98	35.06	17439.94	1431.53	362.95	1794.48	1038.10
	<b>std</b> 0.86 13.72		13.72	322879.45	1255.94	692.02	1502.52	7749.29
	min	0.00	18.00	0.00	7.35	0.03	34.77	0.00
	25%	0.00	25.00	1800.00	729.54	35.00	980.53	0.00
	50%	1.00	31.00	3000.00	1146.42	381.52	1466.85	0.00
	<b>75%</b> 1.00 42		42.00	4500.00	1906.34	487.50	2221.69	0.00
	<b>max</b> 5.00 100.00		8000000.00	15030.96	11700.00	16188.51	98915.00	
	min 25% 50% 75%	0.00 0.00 1.00	18.00 25.00 31.00 42.00	0.00 1800.00 3000.00 4500.00	7.35 729.54 1146.42 1906.34	0.03 35.00 381.52 487.50	34.77 980.53 1466.85 2221.69	

In [167... df\_final4.columns

```
Index(['no_cars', 'gender', 'age', 'income', 'political_party', 'education',
Out[167]:
                  'postal_code', 'EUROSTAT', 'RLK2022', 'KTU2022', 'NUTS1_NAME',
                  'NUTS2_NAME', 'NUTS3_NAME', 'CO2_housing', 'CO2_electricity',
                  'CO2_housing_electricity', 'CO2_cruise', 'CO2_flight',
                  'CO2_public_transport', 'CO2_car1', 'CO2_car2', 'CO2_car3', 'CO2_car4',
                  'CO2_car5', 'CO2_car_total', 'CO2_mobility', 'CO2_food',
                  'CO2_other_consumption', 'public_emission', 'CO2_total',
                  'belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total', 'batch', 'engine_1',
                  'engine_2', 'engine_3', 'engine_4', 'engine_5', 'engine_6', 'engine_7',
                  'engine_8', 'engine_9', 'engine_10',
                  'actual_rank_CO2_housing_electricity1', 'actual_rank_CO2_mobility1',
                  'actual_rank_CO2_food1', 'actual_rank_CO2_other_consumption1',
                  'actual_rank_CO2_total1', 'actual_rank_CO2_housing_electricity2',
                  'actual_rank_CO2_mobility2', 'actual_rank_CO2_food2',
                  'actual_rank_CO2_other_consumption2', 'actual_rank_CO2_total2',
                  'final_belief_housing_electricity', 'final_belief_mobility',
                  'final_belief_food', 'final_belief_other_consumption',
                  'final_belief_total'],
                 dtype='object')
```

In [168... df\_final4.head()

Out[168]:		no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK2
	25	1.00	Weiblich	65	3000.00	CDU/CSU	(Fach-) Hochschulabschluss (Bachelor, Master,	66440	PU	zeı
	26	2.00	Weiblich	59	800.00	8	Allgemeine oder fachgebundene Hochschulreife/A	65933	PU	zeı
	27	0.00	Weiblich	60	1750.00	8	Berufsausbildung, Lehre oder Ausbildung an ein	95028	IN	peri <sub>l</sub>
	28	1.00	Männlich	73	2500.00	SPD	Realschulabschluss (Mittlere Reife) oder gleic	63741	IN	zeı
	30	0.00	Männlich	43	2500.00	7	Berufsausbildung, Lehre oder Ausbildung an ein	13059	PU	zeı
4										•

### Note 5: clean the political party variables

In [169... df final4.columns

```
Index(['no_cars', 'gender', 'age', 'income', 'political_party', 'education',
Out[169]:
                  'postal_code', 'EUROSTAT', 'RLK2022', 'KTU2022', 'NUTS1_NAME',
                  'NUTS2_NAME', 'NUTS3_NAME', 'CO2_housing', 'CO2_electricity',
                  'CO2_housing_electricity', 'CO2_cruise', 'CO2_flight',
                  'CO2_public_transport', 'CO2_car1', 'CO2_car2', 'CO2_car3', 'CO2_car4',
                  'CO2_car5', 'CO2_car_total', 'CO2_mobility', 'CO2_food',
                  'CO2_other_consumption', 'public_emission', 'CO2_total',
                  'belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total', 'batch', 'engine_1',
                  'engine_2', 'engine_3', 'engine_4', 'engine_5', 'engine_6', 'engine_7',
                  'engine 8', 'engine 9', 'engine 10',
                  'actual_rank_CO2_housing_electricity1', 'actual_rank_CO2_mobility1',
                  'actual_rank_CO2_food1', 'actual_rank_CO2_other_consumption1',
                  'actual_rank_CO2_total1', 'actual_rank_CO2_housing_electricity2',
                  'actual_rank_CO2_mobility2', 'actual_rank_CO2_food2',
                  'actual_rank_CO2_other_consumption2', 'actual_rank_CO2_total2',
                  'final_belief_housing_electricity', 'final_belief_mobility',
                  'final_belief_food', 'final_belief_other_consumption',
                  'final_belief_total'],
                 dtype='object')
          ## change the column names for the differences between the actual ranks and the estima
In [170...
          df_final4 = df_final4.rename(columns={'NUTS1_NAME':'federal_state',
                  'final_belief_housing_electricity':'belief_diff_housing_electricity',
                  'final_belief_mobility':'belief_diff_mobility',
                  'final_belief_food':'belief_diff_food', 'final_belief_other_consumption':'belie
                  'final_belief_total':'belief_diff_total'})
          df final4['political_party'].unique()
In [171...
          array(['CDU/CSU', '8', 'SPD', '7', 'FDP', 'Bündnis 90/Die Grünen', 'AfD',
Out[171]:
                  'Die Linke', 'Einer anderen Partei', 'Bündnis Sarah Wagenknecht'],
                 dtype=object)
          ## clean the variables for political party value 7 and 8
In [172...
          df_final4['political_party'].replace('7', 'Einer anderen Partei', inplace=True)
          df_final4['political_party'].replace('8', 'Keine Angabe', inplace=True)
          df_final4['political_party'].unique()
          array(['CDU/CSU', 'Keine Angabe', 'SPD', 'Einer anderen Partei', 'FDP',
Out[172]:
                  'Bündnis 90/Die Grünen', 'AfD', 'Die Linke',
                  'Bündnis Sarah Wagenknecht'], dtype=object)
          df final4.head()
In [173...
```

						_	0_	_				
[173]:	no	o_cars	gende	age	income	politica	l_party		education	postal_code	EUROSTAT	RLK2
	25	1.00	Weiblich	n 65 :	3000.00	CE	DU/CSU		(Fach-) nulabschluss or, Master,	66440	PU	zeı
	26	2.00	Weiblich	n 59	800.00	Keine A	Angabe	fach	emeine oder igebundene chulreife/A	65933	PU	zei
	27	0.00	Weiblich	n 60	1750.00	Keine A	Angabe		ausbildung, Lehre oder ung an ein	95028	IN	peri <sub>l</sub>
	28	1.00 N	Männlich	n 73	2500.00		SPD	(Mi	ulabschluss ittlere Reife) oder gleic	63741	IN	zeı
	30	0.00 N	Männlich	a 43	2500.00	Einer a	inderen Partei		ausbildung, Lehre oder ung an ein	13059	PU	zeı
												•
	len(d	f_final	4)									
	614	1_1 111a1	-4)									
]:	014											
•••		tions.d nal4.de			_format	= '{:.	.0f}'.f	Format				
]:		no_cars	s age	income	CO2_l	housing	CO2_el	ectricity	CO2_housi	ng_electricity	CO2_cruise	CO2
	count	614	4 614	614	ļ	614		614		614	614	
	mean	1	1 35	17440	)	1432		363		1794	1038	
	std	1	1 14	322879		1256		692		1503	7749	
	min	C	) 18	C	)	7		0		35	0	
	25%	C	) 25	1800	)	730		35		981	0	
	50%	1	1 31	3000	)	1146		382		1467	0	
	75%	1	1 42	4500	)	1906		488		2222	0	
	max	5	5 100	8000000		15031		11700		16189	98915	
												•

# Note 6: removing the outliers in the income column

In [176... df\_final4.sort\_values(by=['income'], ascending=False).head(10)

Out[176]:		no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLI
	363	3	Männlich	19	8000000	AfD	Realschulabschluss (Mittlere Reife) oder gleic	90587	PU	2
	450	3	Männlich	27	194267	Bündnis Sarah Wagenknecht	(Fach-) Hochschulabschluss (Bachelor, Master,	50126	PU	7
	723	1	Männlich	33	150000	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	59065	PU	ī
	456	3	Männlich	19	100000	SPD	Allgemeine oder fachgebundene Hochschulreife/A	33102	IN	2
	727	0	Männlich	27	60000	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	40221	PU	ī
	736	1	Weiblich	21	60000	Einer anderen Partei	Allgemeine oder fachgebundene Hochschulreife/A	10589	PU	7
	237	2	Weiblich	27	50000	Einer anderen Partei	Berufsausbildung, Lehre oder Ausbildung an ein	19053	IN	рє
	665	1	Männlich	35	40000	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	20249	PU	7
	719	3	Männlich	19	30000	CDU/CSU	Allgemeine oder fachgebundene Hochschulreife/A	85135	IN	рє
	554	2	Männlich	18	20000	FDP	Allgemeine oder fachgebundene Hochschulreife/A	47800	PU	2
4										•
In [177		_				ottom values = '{:.2f}'.fo	rmat			

df\_final4.sort\_values(by=['income'], ascending=True).head(30)

Out[177]:		no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK
	591	2.00	Männlich	21	0.00	Bündnis Sarah Wagenknecht	Allgemeine oder fachgebundene Hochschulreife/A	75031	IN	Zı
	102	1.00	Männlich	47	0.00	Einer anderen Partei	Berufsausbildung, Lehre oder Ausbildung an ein	74594	PR	pei
	269	3.00	Männlich	54	0.00	CDU/CSU	(Fach-) Hochschulabschluss (Bachelor, Master,	73557	IN	Z
	293	0.00	Weiblich	23	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	35041	IN	Z
	98	2.00	Männlich	23	0.00	FDP	(Fach-) Hochschulabschluss (Bachelor, Master,	76593	IN	Z
	222	1.00	Weiblich	68	0.00	SPD	Allgemeine oder fachgebundene Hochschulreife/A	44795	PU	Z
	95	1.00	Weiblich	53	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	79312	IN	Z
	582	0.00	Weiblich	25	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	35037	IN	Z
	213	2.00	Männlich	58	0.00	CDU/CSU	Realschulabschluss (Mittlere Reife) oder gleic	97070	IN	Z
	525	0.00	Männlich	21	0.00	CDU/CSU	Allgemeine oder fachgebundene Hochschulreife/A	64409	PU	Z
	270	1.00	Weiblich	18	0.00	Einer anderen Partei	Realschulabschluss (Mittlere Reife) oder gleic	29225	IN	реі
	34	2.00	Männlich	62	0.00	Keine Angabe	(Fach-) Hochschulabschluss (Bachelor, Master,	46149	PU	Z
	463	3.00	Männlich	23	0.00	Die Linke	(Fach-) Hochschulabschluss (Bachelor, Master,	71334	PU	Z
	208	1.00	Weiblich	22	1.20	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	99089	IN	Z
	349	1.00	Weiblich	29	2.00	CDU/CSU	Berufsausbildung, Lehre oder Ausbildung an ein	45307	PU	Z

	no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK
478	1.00	Weiblich	23	3.00	Die Linke	Allgemeine oder fachgebundene Hochschulreife/A	48485	IN	Z
479	0.00	Weiblich	32	6.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	80639	PU	Z
607	1.00	Weiblich	26	12.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	86153	IN	Z
563	1.00	Weiblich	30	90.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	80993	PU	Z
66	1.00	Weiblich	67	100.00	Keine Angabe	(Fach-) Hochschulabschluss (Bachelor, Master,	22337	PU	Z
730	0.00	Männlich	35	100.00	Einer anderen Partei	Allgemeine oder fachgebundene Hochschulreife/A	97859	PR	реі
200	0.00	Weiblich	20	200.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	73098	IN	Z
568	0.00	Männlich	38	200.00	Einer anderen Partei	Allgemeine oder fachgebundene Hochschulreife/A	66709	IN	Z
781	0.00	Weiblich	20	400.00	CDU/CSU	Allgemeine oder fachgebundene Hochschulreife/A	34125	IN	Z
815	0.00	Weiblich	24	400.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	97070	IN	Z
749	0.00	Weiblich	22	400.00	Einer anderen Partei	Doktorgrad oder Habilitation	80804	PU	Z
802	0.00	Weiblich	21	500.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	20535	PU	Z
204	2.00	Weiblich	42	500.00	Einer anderen Partei	Realschulabschluss (Mittlere Reife) oder gleic	26605	IN	pei
587	0.00	Weiblich	18	520.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	10243	PU	Z
640	0.00	Männlich	23	530.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss	76131	PU	7

```
In [178... ## delete the rows where the income answered were 1.2, 2, 3, 6, 12 as these answers do
## the row indices of those data points are as follows: 208, 349, 478, 479, 607


df_final4 = df_final4.drop([208, 349, 478, 479, 607])

In [179... ## checking if the rows are dropped
pd.options.display.float_format = '{:.2f}'.format
```

df\_final4.sort\_values(by=['income'], ascending=True).head(30)


Out[179]:		no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK
	98	2.00	Männlich	23	0.00	FDP	(Fach-) Hochschulabschluss (Bachelor, Master,	76593	IN	Z
	222	1.00	Weiblich	68	0.00	SPD	Allgemeine oder fachgebundene Hochschulreife/A	44795	PU	Z
	269	3.00	Männlich	54	0.00	CDU/CSU	(Fach-) Hochschulabschluss (Bachelor, Master,	73557	IN	Z
	270	1.00	Weiblich	18	0.00	Einer anderen Partei	Realschulabschluss (Mittlere Reife) oder gleic	29225	IN	реі
	293	0.00	Weiblich	23	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	35041	IN	Z
	102	1.00	Männlich	47	0.00	Einer anderen Partei	Berufsausbildung, Lehre oder Ausbildung an ein	74594	PR	реі
	591	2.00	Männlich	21	0.00	Bündnis Sarah Wagenknecht	Allgemeine oder fachgebundene Hochschulreife/A	75031	IN	Z
	95	1.00	Weiblich	53	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	79312	IN	Z
	582	0.00	Weiblich	25	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	35037	IN	Z
	525	0.00	Männlich	21	0.00	CDU/CSU	Allgemeine oder fachgebundene Hochschulreife/A	64409	PU	Z
	213	2.00	Männlich	58	0.00	CDU/CSU	Realschulabschluss (Mittlere Reife) oder gleic	97070	IN	Z
	34	2.00	Männlich	62	0.00	Keine Angabe	(Fach-) Hochschulabschluss (Bachelor, Master,	46149	PU	Z
	463	3.00	Männlich	23	0.00	Die Linke	(Fach-) Hochschulabschluss (Bachelor, Master,	71334	PU	Z
	563	1.00	Weiblich	30	90.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	80993	PU	Z
	730	0.00	Männlich	35	100.00	Einer anderen Partei	Allgemeine oder fachgebundene Hochschulreife/A	97859	PR	реі

	no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK
66	1.00	Weiblich	67	100.00	Keine Angabe	(Fach-) Hochschulabschluss (Bachelor, Master,	22337	PU	Z
568	0.00	Männlich	38	200.00	Einer anderen Partei	Allgemeine oder fachgebundene Hochschulreife/A	66709	IN	Z
200	0.00	Weiblich	20	200.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	73098	IN	Z
781	0.00	Weiblich	20	400.00	CDU/CSU	Allgemeine oder fachgebundene Hochschulreife/A	34125	IN	Z
815	0.00	Weiblich	24	400.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	97070	IN	Z
749	0.00	Weiblich	22	400.00	Einer anderen Partei	Doktorgrad oder Habilitation	80804	PU	Z
802	0.00	Weiblich	21	500.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	20535	PU	Z
204	2.00	Weiblich	42	500.00	Einer anderen Partei	Realschulabschluss (Mittlere Reife) oder gleic	26605	IN	реі
587	0.00	Weiblich	18	520.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	10243	PU	Z
640	0.00	Männlich	23	530.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	76131	PU	Z
817	0.00	Weiblich	27	538.00	FDP	(Fach-) Hochschulabschluss (Bachelor, Master,	69181	PU	Z
559	0.00	Männlich	66	560.00	Bündnis Sarah Wagenknecht	(Fach-) Hochschulabschluss (Bachelor, Master,	46348	IN	Z
614	0.00	Weiblich	25	570.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	72072	IN	Z
373	0.00	Weiblich	22	600.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	15230	IN	peı
32	1.00	Weiblich	57	600.00	CDU/CSU	Realschulabschluss (Mittlere Reife) oder gleic	78244	IN	Z



```
In [183... df_var_income_ol = df_final4[df_final4['income']<1*(10**6)]
    df_var_income_ol.hist(column='income')</pre>
```


Out[183]: array([[<AxesSubplot:title={'center':'income'}>]], dtype=object)



```
In [184... # right-skewed distribution

df_var_income_ol2 = df_final4[df_final4['income']<20000]
    df_var_income_ol2.hist(column='income')</pre>
```


Out[184]: array([[<AxesSubplot:title={'center':'income'}>]], dtype=object)



```
In [185... df_var_income_ol3 = df_final4[df_final4['income']<10000]

df_var_income_ol3.hist(column='income')</pre>
```

Out[185]: array([[<AxesSubplot:title={'center':'income'}>]], dtype=object)



```
In [186... # high income class, outliers of more than EUR 10,000 net monthly income will be omitt

df_final5 = df_final4[df_final4['income']<10000]
    df_final5.sort_values(by=['income'], ascending=False).head()</pre>
```

Out[186]:		no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK
	673	1.00	Weiblich	27	9000.00	FDP	(Fach-) Hochschulabschluss (Bachelor, Master,	80805	PU	zε
	579	0.00	Weiblich	34	9000.00	Einer anderen Partei	Realschulabschluss (Mittlere Reife) oder gleic	10557	PU	zε
	471	1.00	Weiblich	42	8500.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	81375	PU	zε
	294	3.00	Weiblich	22	8500.00	FDP	(Fach-) Hochschulabschluss (Bachelor, Master,	46562	PU	zε
	634	1.00	Weiblich	19	8000.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	72124	IN	z€
4										•
In [187	df_f	inal5.s	ort_valu	es (by	/=['inco	me'], ascendi	ng= <b>True</b> ).head(30)			

Out[187]:		no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK
	102	1.00	Männlich	47	0.00	Einer anderen Partei	Berufsausbildung, Lehre oder Ausbildung an ein	74594	PR	реі
	222	1.00	Weiblich	68	0.00	SPD	Allgemeine oder fachgebundene Hochschulreife/A	44795	PU	Z
	463	3.00	Männlich	23	0.00	Die Linke	(Fach-) Hochschulabschluss (Bachelor, Master,	71334	PU	Z
	213	2.00	Männlich	58	0.00	CDU/CSU	Realschulabschluss (Mittlere Reife) oder gleic	97070	IN	Z
	525	0.00	Männlich	21	0.00	CDU/CSU	Allgemeine oder fachgebundene Hochschulreife/A	64409	PU	Z
	98	2.00	Männlich	23	0.00	FDP	(Fach-) Hochschulabschluss (Bachelor, Master,	76593	IN	Z
	582	0.00	Weiblich	25	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	35037	IN	Z
	591	2.00	Männlich	21	0.00	Bündnis Sarah Wagenknecht	Allgemeine oder fachgebundene Hochschulreife/A	75031	IN	Z
	95	1.00	Weiblich	53	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	79312	IN	Z
	293	0.00	Weiblich	23	0.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	35041	IN	Z
	270	1.00	Weiblich	18	0.00	Einer anderen Partei	Realschulabschluss (Mittlere Reife) oder gleic	29225	IN	реі
	269	3.00	Männlich	54	0.00	CDU/CSU	(Fach-) Hochschulabschluss (Bachelor, Master,	73557	IN	Z
	34	2.00	Männlich	62	0.00	Keine Angabe	(Fach-) Hochschulabschluss (Bachelor, Master,	46149	PU	Z
	563	1.00	Weiblich	30	90.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	80993	PU	Z
	66	1.00	Weiblich	67	100.00	Keine Angabe	(Fach-) Hochschulabschluss (Bachelor, Master,	22337	PU	Z

	no_cars	gender	age	income	political_party	education	postal_code	EUROSTAT	RLK
730	0.00	Männlich	35	100.00	Einer anderen Partei	Allgemeine oder fachgebundene Hochschulreife/A	97859	PR	pei
568	0.00	Männlich	38	200.00	Einer anderen Partei	Allgemeine oder fachgebundene Hochschulreife/A	66709	IN	Z
200	0.00	Weiblich	20	200.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	73098	IN	Z
815	0.00	Weiblich	24	400.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	97070	IN	Z
781	0.00	Weiblich	20	400.00	CDU/CSU	Allgemeine oder fachgebundene Hochschulreife/A	34125	IN	Z
749	0.00	Weiblich	22	400.00	Einer anderen Partei	Doktorgrad oder Habilitation	80804	PU	Z
204	2.00	Weiblich	42	500.00	Einer anderen Partei	Realschulabschluss (Mittlere Reife) oder gleic	26605	IN	pei
802	0.00	Weiblich	21	500.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	20535	PU	Z
587	0.00	Weiblich	18	520.00	Bündnis 90/Die Grünen	Allgemeine oder fachgebundene Hochschulreife/A	10243	PU	Z
640	0.00	Männlich	23	530.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	76131	PU	Z
817	0.00	Weiblich	27	538.00	FDP	(Fach-) Hochschulabschluss (Bachelor, Master,	69181	PU	Z
559	0.00	Männlich	66	560.00	Bündnis Sarah Wagenknecht	(Fach-) Hochschulabschluss (Bachelor, Master,	46348	IN	Z
614	0.00	Weiblich	25	570.00	Bündnis 90/Die Grünen	(Fach-) Hochschulabschluss (Bachelor, Master,	72072	IN	Z
199	3.00	Männlich	22	600.00	FDP	Allgemeine oder fachgebundene Hochschulreife/A	67227	PU	Z
32	1.00	Weiblich	57	600.00	CDU/CSU	Realschulabschluss (Mittlere Reife) oder gleic	78244	IN	Z


```
In [188...
           len(df final5)
Out[188]:
In [189...
           df_final5.columns
          Index(['no_cars', 'gender', 'age', 'income', 'political_party', 'education',
Out[189]:
                  'postal_code', 'EUROSTAT', 'RLK2022', 'KTU2022', 'federal_state',
                  'NUTS2_NAME', 'NUTS3_NAME', 'CO2_housing', 'CO2_electricity',
                  'CO2_housing_electricity', 'CO2_cruise', 'CO2_flight',
                  'CO2_public_transport', 'CO2_car1', 'CO2_car2', 'CO2_car3', 'CO2_car4',
                  'CO2_car5', 'CO2_car_total', 'CO2_mobility', 'CO2_food',
                  'CO2_other_consumption', 'public_emission', 'CO2_total',
                  'belief_housing_electricity', 'belief_mobility', 'belief_food',
                  'belief_other_consumption', 'belief_total', 'batch', 'engine_1',
                  'engine_2', 'engine_3', 'engine_4', 'engine_5', 'engine_6', 'engine_7',
                  'engine 8', 'engine 9', 'engine 10',
                  'actual_rank_CO2_housing_electricity1', 'actual_rank_CO2_mobility1',
                  'actual_rank_CO2_food1', 'actual_rank_CO2_other_consumption1',
                  'actual_rank_CO2_total1', 'actual_rank_CO2_housing_electricity2',
                  'actual_rank_CO2_mobility2', 'actual_rank_CO2_food2',
                  'actual_rank_CO2_other_consumption2', 'actual_rank_CO2_total2',
                  'belief_diff_housing_electricity', 'belief_diff_mobility',
                  'belief_diff_food', 'belief_diff_other_consumption',
                  'belief diff total'],
                 dtype='object')
           ### Columns in the final data for R
In [190...
           df_final_save = df_final5[['age', 'income', 'political_party', 'education',
                                'EUROSTAT', 'RLK2022', 'KTU2022', 'federal_state',
                                'CO2_housing', 'CO2_electricity', 'CO2_housing_electricity', 'CO2
                  'CO2_car3', 'CO2_car4', 'CO2_car5', 'CO2_car_total', 'CO2_mobility',
                  'CO2_food', 'CO2_other_consumption', 'public_emission', 'CO2_total',
                                      'belief_diff_housing_electricity', 'belief_diff_mobility',
                  'belief_diff_food', 'belief_diff_other_consumption',
                  'belief_diff_total', 'batch', 'engine_1',
                  'engine_2', 'engine_3', 'engine_4', 'engine_5', 'engine_6', 'engine_7',
                  'engine_8', 'engine_9', 'engine_10']]
          df final save.head()
In [191...
```

Out[191]:		age	income	political_	party	education	EUROSTAT	RLK2022		KTU2022	feder
	25	65	3000.00	CDU		(Fach-) ochschulabschluss achelor, Master,	PU	zentral	Städt	tischer Kreis	5
	26	59	800.00	Keine Ar		Allgemeine oder fachgebundene dochschulreife/A	PU	sehr zentral	kreisfrei	e Großstadt	
	27	60	1750.00	Keine Ar	ngabe	Berufsausbildung, Lehre oder usbildung an ein	IN	peripher		ner Kreis mit ngsansätzen	
	28	73	2500.00		R SPD	ealschulabschluss (Mittlere Reife) oder gleic	IN	sehr zentral	Städt	tischer Kreis	
	30	43	2500.00	Einer an	aeren Partoi	Berufsausbildung, Lehre oder usbildung an ein	PU	sehr zentral	kreisfrei	e Großstadt	
4											•
In [192	###	save	the cl	Leaned da	ıta for ı	Regression					
					-	aned_R_final_b	atch_engin	e.csv')			
In [193	###	# Con	ntinue w	vith the	explora	tory data anal	ysis with:	df_fina	L2		
	4£ .										
	u1_	final	.5 • head (	()							
Out[193]:	u1_	final			income	political_party	edı	ıcation p	ostal_code	EUROSTAT	RLK2
Out[193]:	25	no_ca	ars ge					(Fach-) schluss	ostal_code 66440	<b>EUROSTAT</b> PU	RLK2
Out[193]:		<b>no_ca</b>	<b>nrs ge</b> 00 Wei	nder age			Hochschulab	(Fach-) schluss aster, ne oder undene			
Out[193]:	25	1.	oo Wei	<b>nder age</b> blich 65	3000.00	CDU/CSU Keine Angabe	Hochschulab (Bachelor, Ma Allgemeir fachgebu Hochschulre Berufsausb	(Fach-) schluss aster, ne oder undene eife/A sildung, re oder	66440	PU	zeı
Out[193]:	25	1. 2. 0.	oo Wei	nder age blich 65 blich 59 blich 60	3000.00	CDU/CSU Keine Angabe	Hochschulab (Bachelor, Ma Allgemeir fachgebe Hochschulre Berufsausb Leh Ausbildung a Realschulab (Mittlere	(Fach-) schluss aster, ne oder undene eife/A bildung, re oder an ein	66440 65933	PU	zei
Out[193]:	25 26 27	1. 2. 0.	oo Wei	hder age blich 65 blich 59 blich 60 nlich 73	3000.00 800.00 1750.00	CDU/CSU  Keine Angabe  Keine Angabe	Hochschulab (Bachelor, Ma Allgemeir fachgebe Hochschulre Berufsausb Leh Ausbildung a Realschulab (Mittlere oder	(Fach-) schluss aster, ne oder undene eife/A sildung, re oder an ein schluss e Reife) r gleic	66440 65933 95028	PU PU IN	zei zei perij
Out[193]:	25 26 27 28	1. 2. 0.	oo Wei Wei Man	hder age blich 65 blich 59 blich 60 nlich 73	3000.00 800.00 1750.00 2500.00	CDU/CSU  Keine Angabe  Keine Angabe  SPD	Hochschulab (Bachelor, Ma Allgemeir fachgebe Hochschulre Berufsausb Leh Ausbildung a Realschulab (Mittlere oder Berufsausb Leh	(Fach-) schluss aster, ne oder undene eife/A sildung, re oder an ein schluss e Reife) r gleic	66440 65933 95028 63741	PU PU IN	zei perij
Out[193]:	25 26 27 28	1. 2. 0. 1.	oo Wei OO Wei OO Wei OO Män	hder age blich 65 blich 59 blich 60 nlich 73 nlich 43	3000.00 800.00 1750.00 2500.00	CDU/CSU  Keine Angabe  Keine Angabe  SPD	Hochschulab (Bachelor, Ma Allgemeir fachgebi Hochschulre Berufsausb Leh Ausbildung a Realschulab (Mittlere oder Berufsausb Leh Ausbildung a	(Fach-) schluss aster, ne oder undene eife/A sildung, re oder an ein schluss e Reife) gleic sildung, re oder an ein	66440 65933 95028 63741 13059	PU PU IN PU	zei perij zei


# Comparing the 1, 2, 3 batches

columns to compare: 'CO2\_mobility', 'CO2\_flight', 'CO2\_car\_total'

```
In [195...
           df_final5.groupby(['batch'])['batch'].count()
           batch
Out[195]:
           1
                254
           2
                163
           3
                171
           Name: batch, dtype: int64
           round(100*171/588,2)
In [196...
           29.08
Out[196]:
           batch12 = df_final5[(df_final5['batch'] == 1) | (df_final5['batch'] == 2)]
In [197...
           batch3 = df_final5[df_final5['batch'] == 3]
           print(len(batch12))
           print(len(batch3))
           417
           171
           batch12['CO2_mobility'].hist()
In [198...
           <AxesSubplot:>
Out[198]:
           400
           350
           300
           250
           200
           150
           100
            50
             0
                      25000 50000
                                   75000 100000 125000 150000 175000
In [199...
           batch3['CO2_mobility'].hist()
           <AxesSubplot:>
Out[199]:
```




```
batch12['CO2_mobility'].describe()
In [200...
                       417.00
           count
Out[200]:
           mean
                      6344.51
                     15647.53
           std
                         0.00
           min
           25%
                      1113.36
           50%
                      3215.81
           75%
                      6207.80
           max
                    176807.10
           Name: CO2_mobility, dtype: float64
           batch3['CO2_mobility'].describe()
In [201...
                      171.00
           count
Out[201]:
                     6127.61
           mean
                    13118.98
           std
                        0.00
           min
           25%
                     1035.31
           50%
                     3366.98
           75%
                     5733.45
           max
                    97951.30
           Name: CO2_mobility, dtype: float64
           Flights
In [202...
           hist_data = batch12[batch12['CO2_flight'] < batch12['CO2_flight'].quantile(0.9)]</pre>
           hist_data['CO2_flight'].hist()
           <AxesSubplot:>
Out[202]:
```



```
In [203... hist_data = batch3['C02_flight'] < batch3['C02_flight'].quantile(0.9)]
hist_data['C02_flight'].hist()</pre>
```

#### Out[203]: <AxesSubplot:>



```
In [204... # Creating the two different dataset

data1 = batch12[batch12['C02_flight'] < batch12['C02_flight'].quantile(0.9)]
data2 = batch3[batch3['C02_flight'] < batch3['C02_flight'].quantile(0.9)]

batch12_flight = data1['C02_flight'] # work + personal


batch3_flight = data2['C02_flight'] #only work related</pre>
```

```
batch12_flight.describe()
In [205...
           count
                     374.00
Out[205]:
                     852.60
           mean
                    1247.85
           std
                       0.00
           min
           25%
                       0.00
           50%
                     266.00
           75%
                    1204.00
                    4832.00
           Name: CO2_flight, dtype: float64
In [206...
           batch3_flight.describe()
```

```
count
                    153.00
Out[206]:
                   1498.18
           mean
                   1742.59
           std
           min
                       0.00
           25%
                       0.00
           50%
                    798.00
           75%
                    2408.00
           max
                    6031.00
           Name: CO2_flight, dtype: float64
```


### one-way ANOVA

```
## ONE-way ANOVA
In [207...
           ## H0 (null hypothesis): \mu 1 = \mu 2 = \mu 3 = ... = \mu k (It implies that the means of all the \mu
           ## H1 (null hypothesis): It states that there will be at least one population mean tha
           from scipy.stats import f_oneway
           f_oneway(batch12_flight, batch3_flight) ### reject H0,
           F_onewayResult(statistic=22.791980956316962, pvalue=2.3443052774260043e-06)
Out[207]:
In [208...
           # fail to reject HO: the means of all the population are equal
           f_oneway(batch12['CO2_flight'], batch3['CO2_flight'])
           F_onewayResult(statistic=2.015368436415039, pvalue=0.15624520160985503)
Out[208]:
In [209...
           # fail to reject H0: the means of all the population are equal
           f_oneway(batch12['CO2_car_total'], batch3['CO2_car_total'])
           F_onewayResult(statistic=2.2739860571069284, pvalue=0.13210005471590572)
Out[209]:
           ##### Cars
In [210...
           batch12['CO2_car_total'].hist()
In [211...
           <AxesSubplot:>
Out[211]:
           400
           350
           300
           250
           200
           150
           100
            50
                     10000 20000 30000 40000 50000 60000 70000 80000
In [212...
           batch3['CO2_car_total'].hist()
           <AxesSubplot:>
Out[212]:
```




In [213... hist\_data = batch12['C02\_car\_total'] < batch12['C02\_car\_total'].quantile(0.9)]
hist\_data['C02\_car\_total'].hist()</pre>

### Out[213]: <AxesSubplot:>



In [214... hist\_data = batch3[batch3['CO2\_car\_total'] < batch3['CO2\_car\_total'].quantile(0.9)]
hist\_data['CO2\_car\_total'].hist()</pre>

### Out[214]: <AxesSubplot:>



```
In [215... # Creating the two different dataset

data1 = batch12[batch12['C02_car_total'] < batch12['C02_car_total'].quantile(0.9)]
    data2 = batch3[batch3['C02_car_total'] < batch3['C02_car_total'].quantile(0.9)]

batch12_car = data1['C02_car_total'] # work + personal

batch3_car = data2['C02_car_total'] #only work related

In [216... f_oneway(batch12_car, batch3_car)

Out[216]: F_onewayResult(statistic=17.259753671897645, pvalue=3.804454793665776e-05)

In []:</pre>
```